HW2 資料探勘研究報告

利用多元線性迴歸預測學生考試成績

Multiple Linear Regression for Student Exam Score Prediction

項目	內容
學號	7115064197
課程名稱	物聯網數據分析與應用
姓名	吳佳駿
預測目標	Exam_Score
使用方法	Linear Regression；群組 F 分數；Permutation Importance
報告日期	2026 年 10 月

摘要

本究使用 Kaggle Student Performance Factors 資料集，以 6,607 筆學生紀錄中的 19 個原始輸入特徵預測 Exam_Score。依 CRISP-DM 六階段完成資料理解、理、建模、測試與應用示範；先按 80%／20% 切分資料，數值缺失值使用訓練集的中位數補值，類別缺失值使用眾數補值，再以 One-Hot Encoding 轉換。建立完整 19 特徵線性迴歸模型，並以群組化 F 分數與 Permutation Importance 各選出 15 個原始特徵比較。測試集共 1,322 筆，完整模型 MAE 0.4524、MSE 3.2560、RMSE 1.8044、R^2 0.7696，在三組模型中最佳；兩種 15 特徵模型選到相同欄位，故評估數字相同。結果支持此資料集具有可預測的線性關係，但不構成因果推論，仍須留意極端誤差及資料應用限制。

報告導覽

1. Business Understanding | 究背景與目標
2. Data Understanding｜來源、欄位、統計與缺失值
3. Data Preparation｜切分、補值、編碼與特徵選擇
4. Modeling｜三組多元線性迴歸
5. Evaluation｜指標、預測圖與殘差診斷

6. Deployment｜模擬輸入與使用限制

7. 方法比較與研究結論

8. NotebookLM 研究摘要及 AI 使用紀錄

9. 參考資料

1. Business Understanding（ 商業理解 ）

研究問題：是否能根據讀書時數、出席率、家庭參與、資源、先前成績、學習環境等資訊，預測學生的考試成績？本次是連續數值的監督式迴歸問題，而不是考試及格／不及格的分類問題。

研究目標：（1）建立可解釋的多元線性歸基準模型；（2）比較全部 19 個原始特徵與兩組精簡至 15 個特徵的模型；（3）使用保留測試集量化預測誤差，搭配圖表討論模型適用性。研究不將預測關聯解讀為因果作用，也不以模型取代師判斷。

2. Data Understanding（ 資料理解 ）

資料集名稱：Student Performance Factors。來源：Kaggle 公開 Dataset，網址：https://www.kaggle.com/datasets/lainguyn123/student-performance-factors。由上傳 Notebook 的讀輸出確認，原始資料　6,607 筆、20 欄，除 Exam_Score 目標欄位，候選輸入共 19 個。此資料集在本作業中並非已實際參賽之 Kaggle Competition，無可宣稱的競賽名次。

資料組成	數量
原始紀錄	6,607
總欄位（含 **Y**）	20
原始 **X** 欄位	19
數值 **X** 欄位	6
類別 **X** 欄位	13
目標 **Y**	Exam_Score
重複列	0

六個數值型特徵：Hours_Studied、Attendance、Sleep_Hours、Previous_Scores、Tutoring_Sessions、Physical_Activity。其餘 13 個為類別型：Parental_Involvement、Access_to_Resources、Extracurricular_Activities、Motivation_Level、Internet_Access、Family_Income、Teacher_Quality、School_Type、Peer_Influence、Learning_Disabilities、Parental_Education_Level、Distance_from_Home、Gender。

缺失欄位	缺失筆數	處理方式
Teacher_Quality	78	訓練集衆補值
Parental_Education_Level	90	訓練集衆補值

Distance_from_Home	67	訓練集數補值
其他欄位	0	無需缺失補值

描述統計（來源為 Notebook 執行輸出）：Exam_Score 平均約 67.24；Hours_Studied 平均約 19.98、Attendance 平均約 79.98、Previous_Scores 平均約 75.07。這些為樣本的描述統計，不直接代表因果或未來人群分布。

3. Data Preparation（資料準備）

先移除目標 Exam_Score 缺失資料（原始紀錄在本次執行中均有目標值），再以 random_state=42 將資料切分為訓練集 5,285 筆（80%）與測試集 1,322 筆（20%）。

在 Scikit-learn Pipeline 中，數值欄位使用 SimpleImputer(strategy="median")；類別欄位先使用 SimpleImputer(strategy="most_frequent")，再 OneHotEncoder(handle_unknown="ignore")。所有前處理只在訓練集 fit，測試集只做 transform，避免測試資料資訊滲入訓練流程。19 是「原始輸入欄位數」，完整模型 One-Hot 編碼後有 40 個數值欄位，這兩者不可混為一談。

3.1 特徵選擇方法

方法 B：在訓練集編碼後計算 f_regression F 分數，類別原始欄位以所屬 One-Hot 虛擬變數的最高 F 分數作群組彙整，按原始欄位排序選取前 15 項。此自定義的「群組化單變量 F 分數篩選」，並非直接對 19 個原始欄位執行 SelectKBest。

方法 C：先用訓練集擬合完整 19 特徵模型；僅在訓練集打亂各原始特徵，依 neg_mean_squared_error 評分變化求 Permutation Importance，取前 15 個原始欄位。兩種選擇過程都不使用測試集來挑選欄位。

兩種方法選出的 15 個原始欄位集合完全一致，僅重要性排序不同；排除欄位為 Physical_Activity、Sleep_Hours、School_Type、Gender。

序號	F 分數方法選出之原始特徵	序號	F 分數方法選出之原始特徵
1	Attendance	9	Peer_Influence
2	Hours_Studied	10	Family_Income
3	Previous_Scores	11	Distance_from_Home
4	Tutoring_Sessions	12	Teacher_Quality
5	Access_to_Resources	13	Extracurricular_Activities
6	Parental_Involvement	14	Motivation_Level
7	Parental_Education_Level	15	Internet_Access
8	Learning_Disabilities	16	

F 分數最高者為 Attendance（2664.24）、Hours_Studied（1243.58）；Permutation Importance 最高者也是 Attendance（10.3224）與 Hours_Studied（6.1982）。上述重要性均為本資料及本次模型下的統計指標，不等於影響成績的因果效應。

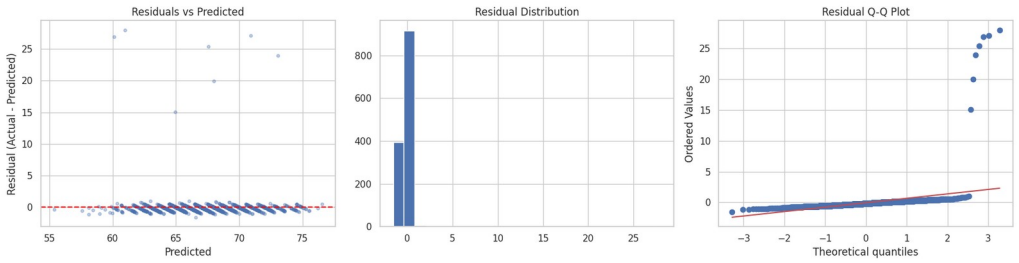


圖 1　數特徵相關性熱圖（源自本次 Colab 輸出）

4. Modeling（模型建立）

三組模型均使用 Scikit-learn LinearRegression（含截距）。Model A 使用全部 19 個原始欄位；Model B 使用群組 F 分數選出的 15 欄；Model C 使用 Permutation Importance 選出的 15 欄，且各自以相同訓練／測試切分重新擬合 Pipeline。

模型	原始 X 欄位數	編碼後欄位數
A_All_19	19	40
B_Group_F_Top15	15	34
C_Permutation_Top15	15	34

完整模型於本次 Colab 顯示截距約 39.4993。個別係數取決於欄位單位與 One-Hot 編碼方式，類別編碼保留全部水準時亦存在共線性，因此不宜孤立地把單一類別係數解釋因果效應。

5. Evaluation（模型評估）

以未參與前處理參數擬合、特徵選擇與模型訓練的 1,322 筆保留測試資料，計算 MAE、MSE、RMSE 及 R^2。MAE／MSE／RMSE 越小越好；R^2 越大一般代表越能解釋測試集目標變異，但並非百分比準確率。

模型	MAE	MSE	RMSE	R^2
A_All_19	0.4524	3.2560	1.8044	0.7696
B_Group_F_Top15	0.5019	3.2856	1.8126	0.7676
C_Permutation_Top15	0.5019	3.2856	1.8126	0.7676

Model A 的 MAE 0.4524、MSE 3.2560、RMSE 1.8044、R^2 0.7696，為此次比較中的最佳結果。Model B 與 C 各為 MAE 0.5019、RMSE 1.8126、R^2 0.7676；由於選出的原始欄位集合相同，並使用相同演算法與資料切分，兩者得到相同預測。19 特徵模型的 R^2 比 15 特徵模型高約 0.0021（未四捨五入差值），屬小幅提升。

本次選擇最佳模型，是就這三組既定方案的保留測試集表現進行描述；若未來要反覆調整超參數並正式選型，應另設驗證集或採交叉驗證與最終獨立測試集。

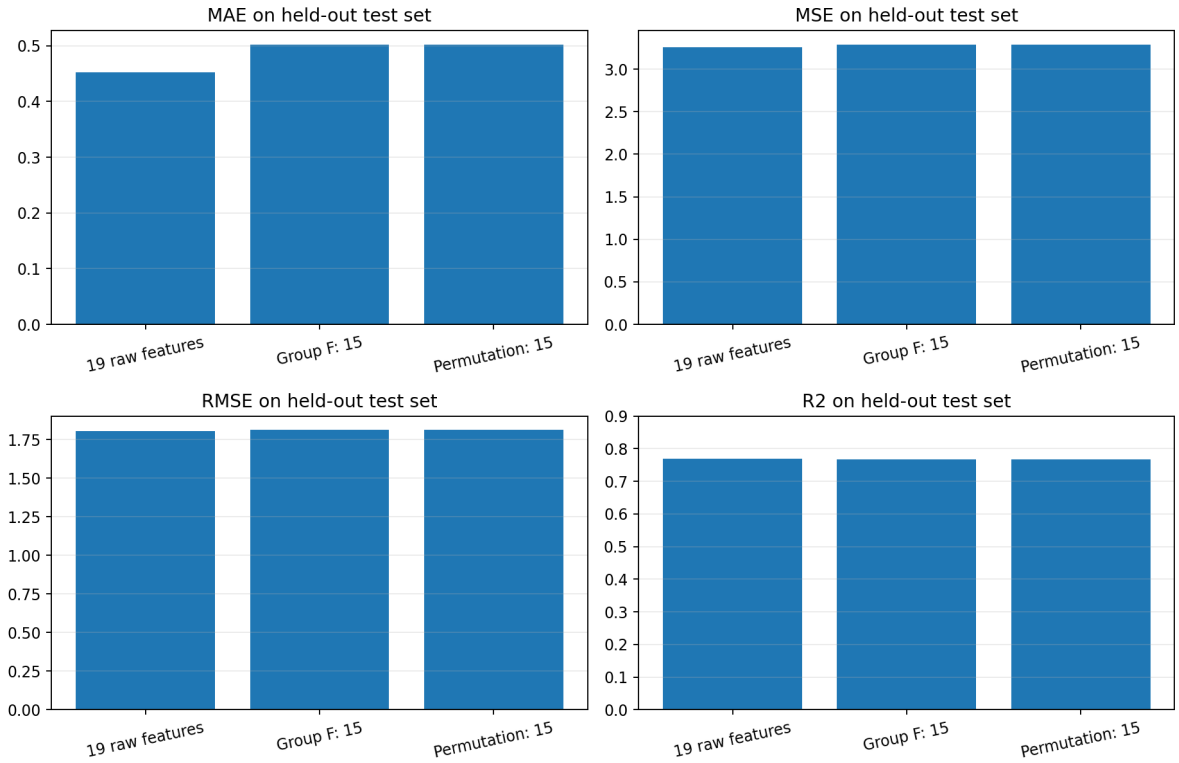


圖 2　三組模型的測試集評估指標（由上傳模型比較 CSV 製圖）

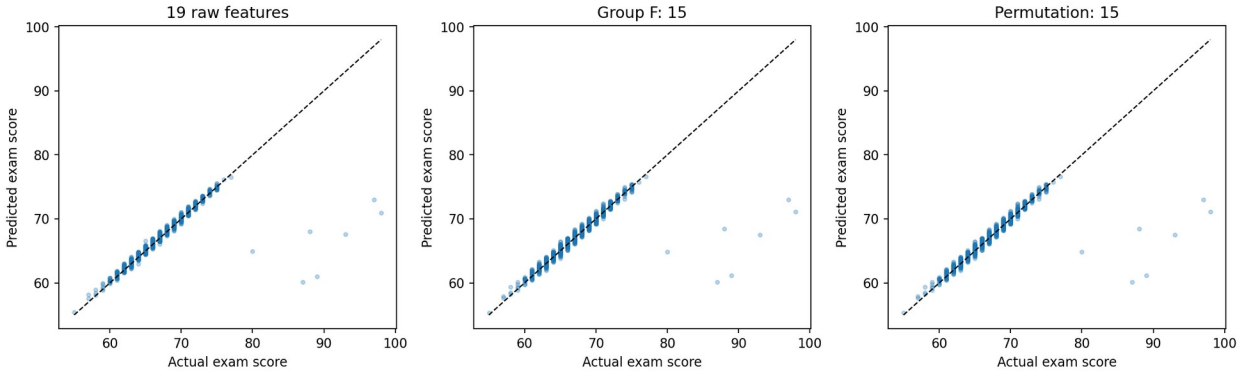


圖 3　真實值與預測值比較；虛線為理想預測 y = x（由預測 CSV 製圖）

圖 3 中多數預測點落在真實成績附近；圖表仍可見偏離理想線的少數點。僅憑圖形不能斷言所有線性迴歸假設成立。

5.1 殘差分析與模型假設

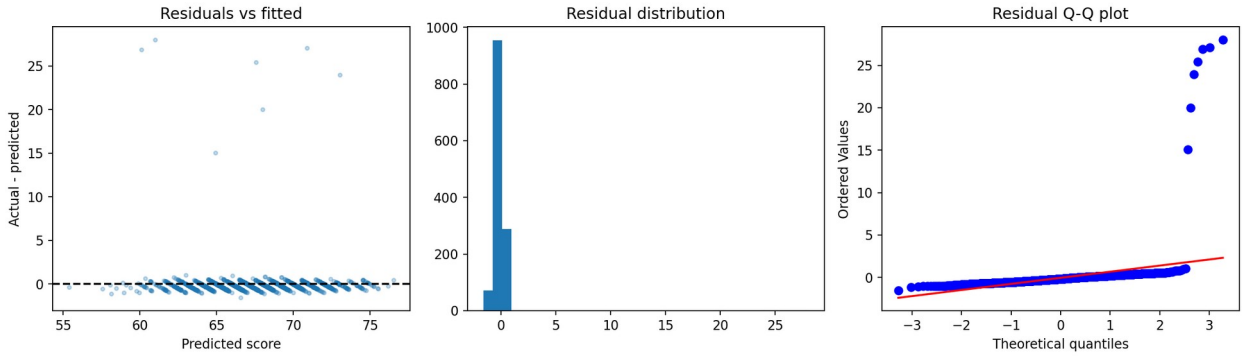


圖 4　完整 19 特徵模型的測試集殘差、分布與 Q-Q 圖（由預測 CSV 製圖）

診斷方向：利用殘差對預測散佈圖檢視系統性彎曲／擴散；以直方圖及 Q-Q 圖觀察殘差是否偏離常態。線性、誤差獨立、等變異、常態與共線性仍須搭配研究設計及進一步檢驗；其中資料為觀察性紀錄，不能從這些圖直接證明因果。

誤差指標補充：MAE 相對低於 RMSE，表示平方損失對少數較大偏差比較敏感；本次不自行刪除極端資料，也不以測試集反覆優化模型。

6. Deployment（模型應用示範）

Notebook 使用訓練集中的一筆既有紀錄示範輸入欄位格式，透過完整 19 特徵 Pipeline 得到預測成績 68.72。這是流程示範，不是新學生、沒有正式部署，也不表示已在學校實務使用。若未來提供新學生資料，需具備與訓練一致的原始欄位名稱與類別定義；也應注意個資、資料授權、偏差風險及成績預測只供輔助判斷。

7. 方法比較與研究結論

方法	本作業角色	特點／限制
Linear Regression	實際建立並評估	可解釋、快速；對線性與殘差條件需檢查
群組 F 分數	實際特徵選擇	單變量評分，未直接考慮多特徵互動
Permutation Importance	實際特徵選擇	依模型打亂欄位評估依賴程度；高度相關欄位可能分攤重要性
Ridge／Lasso	可作未來延伸，未實作	可加入正則化；不能宣稱本研究已比較分數
Random Forest Regression	可作未來延伸，未實作	可捕捉非線性，但解釋模式不同

結論：根據此次測試集，完整 19 原始特徵模型得到三組方案中最低誤差、最高 R^2（0.7696）。兩組不同篩選方法都選到相同的 15 個特徵，說明兩者在本次資料與設定下有一致的選取結果；精簡模型預測能力僅略微下降。研究結果受限於單一 Kaggle 資料集、單次切分及線性模型設定，未進行外部驗證，也不應將預測關聯推論為學生表現的因果機制。

8. NotebookLM 研究摘要（依本人提供的 NotebookLM 輸出整理）

本研究旨在探討影響學生考試成績的關鍵因素。研究採用「學生學習表現數據集」，涵蓋讀書時間、出席率、家庭背景與學習環境等特徵，結合多元線性歸（Multiple Linear Regression）進行建模，透過普通最小平方法（OLS）最小化殘差平方和以預測成績。為提升預測精確度並降低維度，相關研究可採用低變異數過濾、單變量檢定（如 f_regression）、遞迴特徵消除（RFE）與順序特徵選擇（SFS）等策略。模型評估可使用平均絕對誤差（MAE）、均方誤差（MSE）、均方根誤差（RMSE）及決定係數（R^2）衡量預測誤差與擬合優度。線性迴歸具備可解釋性，搭配特徵選擇可降低模型複雜度；但對極端離群值或複雜非線性關係的捕捉能力較弱。

方法區分：上段提及的 VarianceThreshold、RFE、SFS 為 NotebookLM 整理的可用方法，並非本次 Colab 實作。本次實際執行的是原始欄位群組 F 分數篩選與 Permutation Importance，並比較完整 19 欄位與兩組 15 欄位模型；實驗數字請以第 4～5 章及隨附 CSV 為準。

8.1 ChatGPT 使用與對話紀錄

本作業使用 ChatGPT 協助釐清選題條件、設計 CRISP-DM 與 Colab 分析流程、修訂 19 原始特徵版本，及整理模型結果為報告。實際對話紀錄另收錄於 Kaggle 操作學.pdf。

9. 參考資料

〔1〕Kaggle：Student Performance Factors，https://www.kaggle.com/datasets/lainguyn123/student-performance-factors（本研究資料集來源）。

〔2〕本次實驗原始成果：7115064197_hw2.ipynb（含程式與 Colab 執行輸出）。

〔3〕本次實驗匯出：hw2_model_comparison.csv（三模型評估）；hw2_test_predictions.csv（1,322 筆測試預測）。

〔4〕Scikit-learn 官方文件：LinearRegression、Pipeline、ColumnTransformer、SimpleImputer、OneHotEncoder、f_regression、permutation_importance；https://scikit-learn.org/stable/ 。