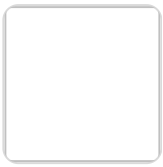
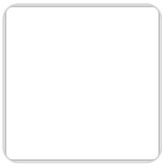
你說：



kaggle怎麼弄

ChatGPT 說：

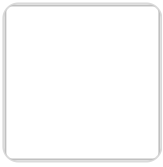
你說：



這是作業內容，請給我步驟

ChatGPT 說：

你說：



已選取 1 個片段

給我詳細過程

ChatGPT 說：

你說：

三、評分標準

文件說明（50%）

CRISP-DM 流程完整且邏輯清楚（25%）

包含 GPT 對話與 NotebookLM 摘要（15%）

有明確說明資料集來源與研究脈絡（10%）
 結果呈現（50%）

模型正確可執行，具特徵選擇與評估（25%）

結果合理、美觀且具有說服力（15%）
呈現出Kaggle名次(若有)/預測結果評估(預測圖、評估指標)（10%）

list kaggle multiple linear regression problems , choose features > 13, < 40

Kaggle Multiple Linear Regression Problems (14–39 Features)

你希望找適合 **Multiple Linear Regression（多元線性回歸）** 的 Kaggle 題目，條件為：
13<Number of Features<4013<Number of Features<40
也就是 **14–39 個輸入特徵**，不包含 Target（預測目標）。
建議優先選擇連續數值預測（Regression）、可使用 **`sklearn.LinearRegression`** 、適合進行 Feature Selection、MSE、RMSE、R^2 與五大回歸假設檢驗的資料集。
特別注意：Kaggle 上常見的 House Prices — Advanced Regression Techniques 有 **79 個原始特徵**，不符合你的原始特徵數限制，但可以透過特徵選擇建立 14–39 特徵的練習版本。
www.kaggle.com&sz=32
Kaggle
+1

Recommended Kaggle Regression Problems

以下區分「原始特徵符合條件」與「需要 Feature Selection 才符合條件」。

#

Kaggle Problem

Features

Target

Suitability

1

Predict the Flood

20

FloodProbability

Excellent

2

Flood Prediction Dataset

20

FloodProbability

Excellent

3

Istanbul Apartment Prices 2026

29 or fewer*

Price
Good
4
Swiss Housing Price Prediction
30
House price
Good; restricted access
5
Human–AI Interaction
20
Trust score
Excellent; synthetic
6
House Prices — Advanced Regression
79 → select 20–30

SalePrice

Excellent for feature selection
*Istanbul 資料集描述為 30 欄，包含價格等欄位；精確輸入特徵數需檢查 CSV。上述資料集的特徵數以來源描述為準，類別編碼後可能增加。
www.kaggle.com&sz=32
Kaggle
+5

My Top 3 for Teaching

China's Yellow River will be choked by ice jams due to global warming, study finds | South China Morning Post
1. Predict the Flood
20 numerical features, continuous target. Best for teaching OLS, MSE, R^2, residual analysis and regression assumptions.
Aerial View of Houses
2. Istanbul Apartment Prices
Suitable for categorical encoding, feature selection, and housing-price regression. Check the dataset columns before modeling.
AISCA
3. Human–AI Interaction
20 original features, 10,100 samples. Useful for studying coefficients, categorical features and multicollinearity.

Suggested Assignment: CRISP-DM + Feature Selection

For any selected dataset, students can complete:

1. **Business Understanding:** Define the continuous prediction target.
2. **Data Understanding:** Verify sample size, feature count, missing values and correlations.
3. **Data Preparation:** Train/test split, missing-value handling and categorical encoding.
4. **Modeling:** Train `LinearRegression`, Ridge and Lasso.
5. **Evaluation:** Compare MAE, MSE, RMSE, R^2 and Adjusted R^2; check the five regression assumptions.

6. **Deployment:** Predict new samples and explain the model.

For Feature Selection, compare **SelectKBest, RFE, Sequential Feature Selection, Lasso and permutation importance**, selecting 14, 20, 25 or 30 features using training data only. **My first choice is Predict the Flood**, because its 20 numerical features meet your constraint directly and avoid the extra complexity of categorical encoding.

ChatGPT 說：

你說：

原本學生的沒辦法嗎

ChatGPT 說：

你說：

我已經完成步驟2了 接下來該怎麼做

ChatGPT 說：

你說：

我已經成功匯出py檔

ChatGPT 說：

你說：

7115064197_hw2... 程式碼

7115064197_hw2... 程式碼

處理時間為 27s

ChatGPT 說：

你說：

請直接使用我上傳的 py 和 ipynb，幫我製作符合老師要求的 19 個原始特徵完整版程式，保留 CRISP-DM、加入特徵選擇、模型比較及完整圖表，並提供修改好的檔案。

處理時間為 2m 17s

ChatGPT 說：

你說：

7115064197_hw2...
程式碼

7115064197_hw2...
程式碼

這是我完成後的檔案，下一步驟該怎麼做

ChatGPT 說：

你說：

7115064197_hw2...
程式碼

Hw2 Model Comparison

Hw2 Test Predictions

我收到重新執行的 Colab 和兩份結果 CSV 了。我先核對程式有沒有完整執行、三組模型的數字是否一致，以及報告可以直接採用哪些結果。

ChatGPT 說：

你說：

7115064197_hw2...
程式碼

Hw2 Model Comparison

Hw2 Test Predictions

ChatGPT 說：

你說：

請使用我上傳的 Colab 和兩份 CSV，直接幫我製作完整的 HW2 CRISP-DM Word 和 PDF 報告，NotebookLM 摘要先保留待補區塊。

處理時間為 2m 10s

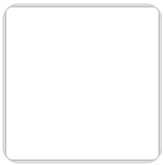
ChatGPT 說：

你說：

好

ChatGPT 說：

你說：



ChatGPT 說：

你說：

請根據我提供的研究來源，分析如何利用多元線性迴歸（Multiple Linear Regression）預測學生考試成績，並探討讀書時間、出席率、家庭背景及學習環境等特徵，如何應用於學生學習表現預測。請同時說明特徵選擇方法與 MAE、MSE、RMSE、R^2 等評估指標，並提供來源引用。

Thoughts

1. 多元線性迴歸（Multiple Linear Regression）預測原理

多元線性迴歸旨在建立連續目標變數（最終考試成績 `Exam_Score` ）與多個解釋變數（特徵）之間的線性關係1。其數學表達式為：

$$\hat{y} = w_0 + w_1 x_1 + w_2 x_2 + \dots + w_p x_p$$

模型透過**普通最小平法（Ordinary Least Squares, OLS）**，最小化實際觀測值 y_i 與模型預測值 $\hat{y}_i$ 之間的殘差平方和（Residual Sum of Squares），從而估算出最優的特徵權重係數 $w = (w_1, \dots, w_p)$ 與截距項 $w_0$23。

2. 學生特徵在學習表現預測中的應用
在學生學習表現數據集（**Student Performance Factors**）中，各特徵變數可歸類為以下層面並投入迴歸模型中分析1：

- **讀書時間與出席率（個人學習投入）**
  - **Hours_Studied（每週讀書時數）**：連續型數值特徵，直接反映學生在課外自主學習的時間投入1。
  - **Attendance（課堂出席率百分比）**：反映學生課堂參與的持續度，通常與成績呈現強烈的正相關1。
- **家庭背景因素**
  - **Parental_Involvement（家長參與度：高/中/低）**、** `Parental_Education_Level` （家長教育程度）**及 **Family_Income（家庭收入等級）**1。這些變數經過類別編碼（如 One-Hot Encoding 或 Ordinal Encoding）後，可幫助模型捕捉家庭資源與支持對學生學業成果的影響。
- **學習環境與學校因素**
  - **Access_to_Resources（學習資源取得）**、** `Internet_Access` （網路設備）**及 **Teacher_Quality（教師教學品質）**：衡量學生所處軟硬體學習環境的良莠1。
  - **School_Type（公私立學校）**、** `Peer_Influence` （同儕影響）**與 **Distance_from_Home（通學距離）**：補足學校類型、社交環境及生活便利度對學生學習專注度的間接衝擊1。

---

3. 特徵選擇方法（Feature Selection Methods）
為了降低模型複雜度、防止過擬合（Overfitting）並提升模型可解釋性，可在 scikit-learn 中運用以下特徵選擇策略：

1. **低變異數過濾（VarianceThreshold）**
   - 計算各特徵的變異數，並設定門檻值自動移除變異數過低或數值幾乎恆定的特徵（例如在多數樣本中皆為相同數值的變數）4。
2. **單變量特徵選擇（Univariate Feature Selection）**

- 透過統計檢定評估單一特徵與目標變數 `Exam_Score` 的相關性1。在迴歸問題中，可使用 `SelectKBest` 或 `SelectPercentile` 搭配 **f_regression**（評估線性依賴性）或 **mutual_info_regression**（評估互資訊與非線性依賴）來選取得分最高的特徵56。

3. **遞迴特徵消除（Recursive Feature Elimination, RFE / RFECV）**
   - 基於拟合後的迴歸模型係數（ `coef_` ），遞迴性地剔除權重最小、影響力最低的特徵27。結合交叉驗證的 **RFECV** 則可自動尋找能達到最佳交叉驗證分數的最佳特徵數量8。
4. **基於模型的特徵選擇（SelectFromModel / L1 懲罰項）**
   - 採用帶有 L1 正則化（L1 Penalty）的模型（如 Lasso 迴歸），利用 L1 範數可將不重要特徵係數壓縮為 0 的特性，搭配 **SelectFromModel** 自動篩選出係數非零的關鍵特徵9。
5. **順序特徵選擇（Sequential Feature Selection, SFS）**
   - 採用貪婪搜尋演算法12。**前向選擇（Forward-SFS）**從空特徵集開始，逐一加入能最大化 CV 分數的特徵；**後向消除（Backward-SFS）**則從全特徵集開始逐一剔除特徵1213。SFS 不需要模型提供 `coef_` 屬性即可運作14。

---

4. 模型評估指標（Evaluation Metrics）
預測模型建立後，需透過以下迴歸評估指標檢驗模型的預測品質與誤差程度：

- **MAE（Mean Absolute Error，平均絕對誤差）**
  - **公式**：$\text{MAE} = \frac{1}{n} \sum_{i=0}^{n-1} |y_i - \hat{y}_i|$15。
  - **說明**：計算實際成績與預測成績之間絕對殘差的平均值15。MAE 以原資料單位（分數）呈現，易於解釋，且對異常值（Outliers）的敏感度低於平方誤差1516。
- **MSE（Mean Squared Error，均方誤差）**
  - **公式**：$\text{MSE} = \frac{1}{n} \sum_{i=0}^{n-1} (y_i - \hat{y}_i)^2$17。

- **說明**：計算殘差平方的期望值17。由於對較大的預測誤差進行二次方放大，因此對離群值與極端誤差非常敏感1617。

- **RMSE（Root Mean Squared Error，均方根誤差）**
  - **公式**：$\text{RMSE} = \sqrt{\text{MSE}}$18。
  - **說明**：為 MSE 取平方根，將誤差單位開方還原回與目標變數 `Exam_Score` 相同的單位，方便衡量模型預測殘差的標準差規模118。

- **R^2（Coefficient of Determination，決定係數）**
  - **公式**：$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$19。
  - **說明**：表示目標變數的變異量中有多少比例可被模型的自變數所解釋20。R^2 最佳值為 1.0，若與僅預測平均值的基準模型相當則為 0.0，若模型表現極差則可能為負值，是評估模型整體擬合優度（Goodness of Fit）的核心指標19。

📊 **後續建議**：如果需要，我可以為你撰寫完整的 Python 實作腳本，利用 `scikit-learn` 對學生成績資料集進行特徵編碼、特徵選擇（如 RFE 與 SelectKBest）以及多元線性迴歸的模型訓練與評估！

儲存至記事

請將上述研究整理成一篇 200～300 字的繁體中文研究摘要，內容包含研究背景、學生考試成績預測方法、多元線性迴歸、特徵選擇，以及模型評估方式，最後說明此研究方法的優點與限制。請根據已提供的來源撰寫，保留引用標記，不要捏造實驗結果。

Thoughts

學生考試成績預測研究摘要

本研究旨在探討影響學生考試成績的關鍵因素12。研究採用「學生學習表現數據集」（涵蓋讀書時間、出席率、家庭背景與學習環境等特徵23），結合多元線性迴歸（Multiple Linear Regression）進行建模，透過普通最小平法（OLS）最小化殘差平方和以預測成績4。為提升預測精確度並降低維度，採用低變異數過濾、單變量檢定（如 `f_regression`）、遞迴特徵消除（RFE）與順序特徵選擇（SFS）等特徵選擇策略5。模型評估則使用平均絕對誤差（MAE）、均方誤差（MSE）、均方根誤差（RMSE）及決定係數（R^2）來衡量預測誤差與擬合優度9。

此方法的**優點**在於線性迴歸具備高度可解釋性，能透過係數直觀評估各特徵的權重影響47，配合特徵選擇可降低維度並提升運算效率5；**限制**則在於模型假設變數間為線性關係，對資料中的極端離群值

或複雜非線性結構的捕捉能力較弱6。

💡 **下一步建議**：若你需要將這篇研究摘要擴充為完整的簡報、心智圖或研究報告，我可以隨時為你生成對應的 Content Studio 產出物！

處理時間為 57s

ChatGPT 說：

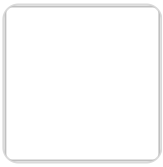
你說：



ChatGPT 說：

7115064197_HW2_CRISP-DM_已補NotebookLM.docx
Word

你說：



ChatGPT 說：